

Platforma pogodowa i analiza jakości powietrza

Autorzy:

Adrian Werel
Paweł Kozikowski
Patrik Nisgorski
Julian Jarosz
Błażej Furmanowski

1. Ogólna struktura projektu

Projekt to kompletna platforma do zbierania, przetwarzania i analizy danych pogodowych oraz jakości powietrza dla 9 polskich miast - Warszawa, Kraków, Gdańsk, Poznań, Wrocław, Białystok, Ostrołęka, Działdowo, Pęcice Małe. System realizuje pełny pipeline ELT: od pobierania danych z API, przez bazę operacyjną i hurtownię danych, aż po prognozowanie zanieczyszczeń powietrza z wykorzystaniem sieci neuronowej.

2. Źródło danych

Dane pogodowe i o jakości powietrza pobierane są z OpenWeather API w wersji One Call 3.0.

Bazowy URL: <https://api.openweathermap.org>

Wykorzystywane endpointy:

- **/data/3.0/onecall** - endpoint One Call 3.0, zwraca w jednym wywołaniu: aktualną pogodę, prognozę godzinową na 48h, prognozę dzienną na 8 dni, prognozę minutową opadów oraz alerty pogodowe z IMGW.
- **/data/2.5/air_pollution** - endpoint Air Pollution API, zwraca indeks jakości powietrza AQI oraz stężenia składników: CO, NO, NO2, O3, SO2, PM2.5, PM10, NH3.

Częstotliwość pobierania:

- Dane pogodowe, alerty i zanieczyszczenia: co 2 minuty.
- Inferencja ML : raz dziennie o północy.

3. Model bazy operacyjnej

Baza operacyjna przechowuje dane bezpośrednio z API. Dane trafiają najpierw do bufora `mapped_data_buffer`, a następnie transformacja SQL rozdziela je do docelowych tabel znormalizowanych.

Tabele w bazie operacyjnej:

- **location** - 9 monitorowanych lokalizacji. Klucz unikalny na parze z walidacją zakresów współrzędnych.
- **weather_condition** - słownik warunków pogodowych z OpenWeather.
- **current_weather** - aktualne warunki pogodowe: temperatura, odczuwalna, ciśnienie, wilgotność, zachmurzenie, widoczność, wiatr, opady. Powiązana z `location` i `weather_condition` przez klucze obce. Unikalność na (`location_id`, `observed_at`).
- **hourly_forecast** - prognoza godzinowa na 48h: te same metryki co `current_weather` plus prawdopodobieństwo opadów. Zawiera `forecast_for` i `retrieved_at`.
- **daily_forecast** - prognoza dzienna na 8 dni: temperatury, fazy księżyca, wschód/zachód słońca, opady.
- **minutely_forecast** - prognoza opadów minuta po minucie.
- **air_pollution** - pomiary jakości powietrza: AQI oraz 8 składników. **weather_alert** - ostrzeżenia meteorologiczne: nadawca, typ zdarzenia, czas rozpoczęcia i zakończenia.

4. Struktura hurtowni danych

Hurtownia danych `weather_warehouse` (PostgreSQL, port 5433) wykorzystuje schemat gwiazdy w schemacie `dw`. Dane ładowane są inkrementalnie z bazy operacyjnej przy użyciu mechanizmu watermarków.

Wymiary


- **dim_date** – data: `full_date`, `day`, `month`, `month_name`, `quarter`, `year`, `day_of_the_week`, `day_name`, `is_weekend`.
- **dim_time** – czas: `full_time`, `hour`, `minute`, `second`, `part_of_the_day`.
- **dim_location** – lokalizacja: `city_name`, `country_code`, `latitude`, `longitude`, `timezone`, `timezone_offset`.

- **dim_weather_condition** – warunki pogodowe: openweather_weather_id, main, description.


Tabele faktów

- **fact_current_weather** – aktualne warunki pogodowe; miary: temp, feels_like, pressure, humidity, clouds, visibility, wind_speed, wind_deg, rain_1h, snow_1h.
- **fact_hourly_forecast** – prognoza godzinowa; miary: temp, feels_like, pressure, humidity, uvi, clouds, visibility, pop, wind_speed, rain_1h, snow_1h.
- **fact_daily_forecast** – prognoza dzienna; miary: temperatury, pressure, humidity, clouds, pop, rain, snow, uvi.
- **fact_minutely_forecast** – prognoza opadów; miara: precipitation.
- **fact_air_pollution** – jakość powietrza; miary: aqi, co, no, no2, o3, so2, pm2_5, pm10, nh3.
- **fact_weather_alert** – ostrzeżenia meteorologiczne; miary: sender_name, event, description, tags, alert_count.
- **fact_forecast_accuracy** – porównanie prognoz z rzeczywistością; miary: forecast_temp, actual_temp, temp_error, abs_temp_error.
- **fact_air_pollution_forecast** – prognozy modelu LSTM na 14 dni; miary: predicted_aqi, predicted_co, predicted_no, predicted_no2, predicted_o3, predicted_so2, predicted_pm2_5, predicted_pm10, predicted_nh3, model_version.


Diagramy schematu gwiazdy



Schemat gwiazdy - aktualna pogoda



Schemat gwiazdy - zanieczyszczenie powietrza



Schemat gwiazdy - dokładność prognoz

Ładowanie inkrementalne

Hurtownia wykorzystuje tabelę dw.etl_watermark do śledzenia ostatnio załadowanego rekordu z każdej tabeli źródłowej. Małe wymiary ładowane są w trybie full load, a pozostałe tabele przyrostowo na podstawie watermarków.

5. Moduł ML

Moduł ML prognozuje wartości 9 wskaźników zanieczyszczenia powietrza na kolejne 14 dni dla każdego monitorowanego miasta.

Model: sieć LSTM w PyTorch.

Dane wejściowe:

- Zanieczyszczenia: aqi, co, no, no2, o3, so2, pm2_5, pm10, nh3
- Pogoda: temp, humidity, wind_speed

Dane wyjściowe: prognozy 9 wskaźników jakości powietrza

Parametry treningu:

- Okno wejściowe: 30 dni
- Horyzont prognozy: 14 dni
- Batch size: 32
- 50 epok
- Ada

Przygotowanie danych: dane dzienne są uzupełniane interpolacją, skalowane do zakresu $[0,1]$ i przekształcane w okna czasowe 30 w 14 dni. Model trenowany jest osobno dla każdej lokalizacji.


Uruchamianie: prognozy generowane są codziennie przez Airflow i zapisywane w hurtowni danych wraz z wersją modelu.

Testy: obejmują poprawność modelu, przygotowania danych, skalowania, interpolacji oraz podstawowe testy integracyjne procesu uczenia.

6. Wizualizacje Power BI


Dashboard Power BI składa się z 6 widoków analitycznych podłączonych do hurtowni danych.

Widok 1: Przegląd pogody




Dashboard główny z kartami KPI oraz wykresem liniowym temperatury w czasie. Slicery umożliwiają filtrowanie po nazwie miasta i dacie.

Widok 2: Prognoza pogody




Wykresy słupkowe prawdopodobieństwa opadów, temperatury w ciągu dnia, indeksu UV i opadów deszczu, a także tabela z prognozą dzienną zawierająca temperatury min/max, prawdopodobieństwo opadów, średnie opady deszczu i śniegu.

Widok 3: Jakość powietrza



Karty KPI ze średnim AQI, CO, PM2.5, NO2 i PM10. Tabela porównawcza prezentuje rozkład zanieczyszczeń w podziale na miasta, umożliwiając identyfikację lokalizacji o najgorszej jakości powietrza.

Widok 4: Przewidywana jakość powietrza



40,93

PM10

data

☐ 13 czerwca 2026

☐ 14 czerwca 2026

☐ 15 czerwca 2026

☐ 16 czerwca 2026

Widok podobny do powyższego, ale czerpiący dane dotyczące przewidywanych zanieczyszczeń z modelu ML.

Widok 5: Alerty pogodowe


Nazwa miasta/miejscowości	Wydarzenie	Nadawca	Początek	Koniec
Białystok	Yellow Thunderstorm warning	IMGW-PIB Centralne Biuro Meteorologicznych Prognoz Morskich w Gdyni	2026-06-15 07:00:00	2026-06-15 23:00:00
Białystok	Yellow Thunderstorm warning	IMGW-PIB Centralne Biuro Prognoz Meteorologicznych - Wydział we Wrocławiu	2026-06-14 11:00:00	2026-06-14 23:00:00
Białystok	Yellow Thunderstorm warning	IMGW-PIB Centralne Biuro Prognoz Meteorologicznych w Warszawie	2026-06-13 12:00:00	2026-06-13 23:00:00
Działdowo	Yellow Thunderstorm warning	IMGW-PIB Centralne Biuro Meteorologicznych Prognoz Morskich w Gdyni	2026-06-15 07:00:00	2026-06-15 23:00:00
Działdowo	Yellow Thunderstorm warning	IMGW-PIB Centralne Biuro Prognoz Meteorologicznych - Wydział we Wrocławiu	2026-06-14 11:00:00	2026-06-14 23:00:00
Działdowo	Yellow Thunderstorm warning	IMGW-PIB Centralne Biuro Prognoz Meteorologicznych w Warszawie	2026-06-13 12:00:00	2026-06-13 23:00:00
Gdańsk	Yellow Thunderstorm warning	IMGW-PIB Centralne Biuro Meteorologicznych Prognoz Morskich w Gdyni	2026-06-15 07:00:00	2026-06-15 23:00:00
Gdańsk	Yellow Thunderstorm warning	IMGW-PIB Centralne Biuro Prognoz Meteorologicznych - Wydział we Wrocławiu	2026-06-14 11:00:00	2026-06-14 23:00:00
Gdańsk	Yellow Thunderstorm warning	IMGW-PIB Centralne Biuro Prognoz Meteorologicznych w Warszawie	2026-06-13 12:00:00	2026-06-13 23:00:00
Ostrołęka	Yellow Thunderstorm warning	IMGW-PIB Centralne Biuro Meteorologicznych Prognoz Morskich w Gdyni	2026-06-15 07:00:00	2026-06-15 23:00:00
Ostrołęka	Yellow Thunderstorm warning	IMGW-PIB Centralne Biuro Prognoz Meteorologicznych - Wydział we Wrocławiu	2026-06-14 11:00:00	2026-06-14 23:00:00
Ostrołęka	Yellow Thunderstorm warning	IMGW-PIB Centralne Biuro Prognoz Meteorologicznych w Warszawie	2026-06-13 12:00:00	2026-06-13 23:00:00
Pęcice-Małe	Yellow Thunderstorm warning	IMGW-PIB Centralne Biuro Prognoz Meteorologicznych - Wydział we Wrocławiu	2026-06-14 11:00:00	2026-06-14 23:00:00
Poznań	Orange high-temperature warning	IMGW-PIB Centralne Biuro Prognoz Meteorologicznych w Warszawie	2026-06-19 11:00:00	2026-06-21 20:00:00
Poznań	Yellow Thunderstorm warning	IMGW-PIB Centralne Biuro Prognoz Meteorologicznych - Wydział we Wrocławiu	2026-06-14 11:00:00	2026-06-14 23:00:00
Poznań	Yellow Thunderstorm warning	IMGW-PIB Centralne Biuro Prognoz Meteorologicznych w Warszawie	2026-06-13 12:00:00	2026-06-13 23:00:00
Warsaw	Yellow Thunderstorm warning	IMGW-PIB Centralne Biuro Prognoz Meteorologicznych - Wydział we Wrocławiu	2026-06-14 11:00:00	2026-06-14 23:00:00
Warsaw	Yellow Thunderstorm warning	IMGW-PIB Centralne Biuro Prognoz Meteorologicznych w Warszawie	2026-06-13 12:00:00	2026-06-13 23:00:00
Wrocław	Orange high-temperature warning	IMGW-PIB Centralne Biuro Prognoz Meteorologicznych w Warszawie	2026-06-19 11:00:00	2026-06-21 20:00:00

Tabela aktywnych ostrzeżeń meteorologicznych z IMGW zawierająca: miasto, typ zdarzenia, nadawcę, czas rozpoczęcia i zakończenia oraz opis ostrzeżenia.

Widok 6: Mapa temperatur w Polsce

Mapa temperatur w Polsce

Temperatura, wilgotność i opis pogody dla wybranych miast



Wizualizacja mapowa temperatury, rozmieszczonymi na mapie Polski w 9 monitorowanych lokalizacjach.

7. Podział pracy

Adrian Werel – PowerBi, Wizualizacja, Schemat SQL hurtownii danych, Schemat SQL bazy operacyjnej, Testy jednostkowe i integracyjne

Paweł Kozikowski – Opracowanie ogólnej architektury aplikacji, zbudowanie skryptów do zarządzania bazą operacyjną oraz hurtownią danych po stronie python`a.

Patryk Nisgorski - Schemat SQL hurtownii danych, Schemat SQL bazy operacyjnej, budowa pipeline ELT, Transformacje w operacyjnej bazie danych i hurtownii, integracja Apache Airflow z projektem

Julian Jarosz – opracowanie modelu ML, integracja Apache Airflow z projektem, opracowanie testów jednostkowych oraz integracyjnych dla modułu ML.

Błażej Furmanowski – Diagramy reprezentujące hurtownie danych oraz bazę operacyjną, Wizualizacja oraz PowerBi